



**T.C.
NEVŞEHİR HACI BEKTAŞ VELİ
ÜNİVERSİTESİ
MÜHENDİSLİK-MİMARLIK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ**



KONU:
Çevresel Verilere Göre
Uygun Ürün Tahmini (Sınıflandırma)
Kaggle - Crop Recommendation Dataset

Dersin Adı: Makine Öğrenmesi

Öğrenci Adı: Aİşe Konur

Numarası: 23260810054

GİRİŞ VE PROBLEM TANIMI

1.1. Problem Tanımı ve Önemi

Bu projenin temel amacı, belirli bir tarım arazisinden alınan toprak analiz sonuçlarını ve o bölgenin iklim verilerini kullanarak, ekilebilecek en verimli mahsulü tahmin etmektir. Problem, makine öğrenimi terminolojisinde bir Çoklu Sınıflandırma (Multi-class Classification) problemidir. Veri setindeki temel girdiler (özellikler) şunlardır:

- Toprak Verileri: Azot (N), Fosfor (P), Potasyum (K) değerleri ve pH seviyesi.
- İklim Verileri: Sıcaklık, nem oranı ve yıllık yağış miktarı.
- Model, bu girdileri analiz ederek 22 farklı ürün türü (pirinç, mısır, kahve vb.) arasından o koşullara en uygun olanı tahmin etmektedir.

1.2. Veri Seti Bilgileri

- Kaynak: Kaggle - Crop Recommendation Dataset.
- Boyut: Veri seti 2200 örnek (satır) ve 8 özellikten (7 bağımsız değişken + 1 hedef değişken) oluşmaktadır.
- Format: Veriler tabular (tablo) formatta olup, ders kapsamında beklenen "en az 1000 örnek ve 8 özellik" kriterlerini tam olarak karşılamaktadır

	N	P	K	temperature	humidity	ph	rainfall	label
0	90	42	43	20.879744	82.002744	6.502985	202.935536	rice
1	85	58	41	21.770462	80.319644	7.038096	226.655537	rice
2	60	55	44	23.004459	82.320763	7.840207	263.964248	rice
3	74	35	40	26.491096	80.158363	6.980401	242.864034	rice
4	78	42	42	20.130175	81.604873	7.628473	262.717340	rice

1.3. Motivasyon

Tarım sektöründe yanlış ürün seçimi; düşük verimlilik, kaynak israfı (su, gübre) ve ekonomik kayıplara yol açmaktadır. Geleneksel yöntemler genellikle çiftçi tecrübesine veya sınırlı toprak analizlerine dayanmaktadır. Bu projede makine öğrenimi tekniklerinin kullanılmasının temel motivasyonları şunlardır:

- Hassas Tarım (Precision Agriculture): Veriye dayalı karar verme süreçleriyle birim alandan alınan verimi maksimize etmek.
- Kaynak Optimizasyonu: Toprağın besin değerlerine en uygun ürünü seçerek aşırı gübreleme veya yanlış sulama gibi çevresel zararları minimize etmek.

- Gıda Güvenliği: İklim değişikliği ve azalan kaynaklar göz önüne alındığında, tarımsal sürdürülebilirliği sağlamak için teknolojik çözümler üretmek.

KEŞİFSEL VERİ ANALİZİ (EDA)

2.1. Temel İstatistiksel Özet

Model eğitime geçmeden önce veri setindeki sayısal özelliklerin dağılımını ve merkezi eğilimlerini anlamak adına tanımlayıcı istatistikler analiz edilmiştir. Veri seti; Azot (N), Fosfor (P), Potasyum (K), Sıcaklık (temperature), Nem (humidity), pH ve Yağış (rainfall) olmak üzere 7 adet sayısal öznitelik içermektedir.

	N	P	K	temperature	humidity	ph	rainfall
count	2200.000000	2200.000000	2200.000000	2200.000000	2200.000000	2200.000000	2200.000000
mean	50.551818	53.362727	48.149091	25.616244	71.481779	6.469480	103.463655
std	36.917334	32.985883	50.647931	5.063749	22.263812	0.773938	54.958389
min	0.000000	5.000000	5.000000	8.825675	14.258040	3.504752	20.211267
25%	21.000000	28.000000	20.000000	22.769375	60.261953	5.971693	64.551686
50%	37.000000	51.000000	32.000000	25.598693	80.473146	6.425045	94.867624
75%	84.250000	68.000000	49.000000	28.561654	89.948771	6.923643	124.267508
max	140.000000	145.000000	205.000000	43.675493	99.981876	9.935091	298.560117


- Potasyum (K) ve Azot (N) değerlerindeki standart sapmanın yüksek olması, farklı ürün gruplarının besin ihtiyaçları arasında belirgin farklar olduğunu göstermektedir.
- Veri setindeki ortalama pH değerinin 6.46 olması, çoğu mahsulün hafif asidik veya nötr topraklarda yetiştirildiğine işaret etmektedir.
- Veri kalitesini doğrulamak amacıyla yapılan incelemede, veri setinde herhangi bir eksik değer (missing value) bulunmadığı tespit edilmiştir. Bu durum, veri setinin temiz olduğunu ve doğrudan ön işleme aşamasına geçilebileceğini göstermektedir.

2.2. Hedef Değişkenin Dağılımı (Sınıf Dengesi)

Makine öğrenimi modellerinin başarısı, eğitim verisindeki sınıfların dengeli dağılmasına bağlıdır.

Veri setindeki hedef değişken olan "label" sütunu incelendiğinde şu sonuçlara ulaşılmıştır:


- Sınıf Sayısı: Veri setinde toplam 22 farklı ürün (sınıf) bulunmaktadır.
- Örnek Sayısı: Her bir ürün türü için tam olarak 100 adet örnek mevcuttur.
- Toplam Veri: 22 ürün * 100 örnek = 2200 satır.



Mükemmel Dengeli Veri (Balanced Dataset): Veri setindeki her bir sınıfın (pirinç, mısır, elma vb.) temsil oranı tam olarak %4.54'tür.


- Avantajı: Sınıfların tamamen eşit olması, modelin herhangi bir sınıfa karşı "taraf" (bias) olmasını engeller. Bu durum, Accuracy (Doğruluk) metriğinin model performansını ölçmek için güvenilir bir metrik olarak kullanılabileceği anlamına gelir; zira azınlık sınıfı sorunu (imbalanced data) bulunmamaktadır.
- Uygulama Notu: Veri setinde sınıf dengesizliği olmadığı için SMOTE gibi sentetik veri artırma tekniklerine ihtiyaç duyulmamıştır.

2.3. Korelasyon Matrisi ve Görselleştirmeler




Değişkenler arasındaki doğrusal ilişkiler incelendiğinde, özelliklerin çoğunun birbiriyle düşük korelasyona sahip olduğu görülmektedir. Ancak korelasyon matrisinde en dikkat çekici ve güçlü ilişki, 0.74 değeri ile P (Fosfor) ve K (Potasyum) arasında saptanmıştır. Bu güçlü pozitif bağ, toprakta bu iki elementin genellikle paralel miktarlarda bulunduğunu ve belirli ürün gruplarının (örneğin üzüm ve elma) hem potasyum hem de fosfor bakımından çok zengin topraklara ihtiyaç duyduğunu doğrulamaktadır. Ayrıca N (Azot) ve P (Fosfor) arasında -0.23 oranında zayıf bir negatif ilişki gözlemlenmiştir. Bu veriler, modelin mahsulleri ayırt ederken özellikle P ve K dengesini kritik bir ayırt edici özellik olarak kullanabileceğine işaret etmektedir.


Özelliklerin Dağılım Histogramları



Her bir değişkenin dağılımı incelendiğinde, pH değerinin normal dağılıma (çan eğrisi) oldukça yakın olduğu görülmüştür. Yağış ve nem verilerinde ise çok modlu dağılımlar gözlemlenmiştir. Bu, veri setindeki 22 farklı ürünün çok farklı iklim ihtiyaçlarına (kurakçıl ve nemcil bitkiler gibi) sahip olduğunun bir göstergesidir.



Azot, fosfor ve potasyum değerleri ürün bazında kutu grafikleriyle incelenmiştir. Özellikle bazı mahsullerin (örneğin kahve ve mısır) azot ihtiyacının diğerlerine göre belirgin şekilde yüksek olduğu, bazı meyvelerin ise potasyum değerlerinde aşırı uç değerlere (outliers) sahip olduğu gözlemlenmiştir. Bu ayrışma, makine öğrenimi modelinin ürünleri sınıflandırırken kullanacağı en güçlü ayırt edici özelliklerden biridir.



Yukarıdaki saçılım grafiği (scatter plot) incelendiğinde, P (Fosfor) ve K (Potasyum) değerlerinin belirli ürün grupları için karakteristik kümeler oluşturduğu açıkça görülmektedir:

- Yüksek P ve K İhtiyacı Olan Ürünler: Grafiğin sağ üst köşesinde ($P > 120$, $K > 190$) izole bir şekilde kümelenen veriler, elma (apple) ve üzüm (grapes) gibi meyvelerin toprakta çok yüksek oranda fosfor ve potasyuma ihtiyaç duyduğunu kanıtlamaktadır. Bu net ayrışma, makine öğrenimi modelinin bu ürünleri diğerlerinden çok yüksek doğrulukla ayırt etmesini sağlayacaktır.
- Orta Seviye Kümelenmeler: Grafiğin orta kısmında ($P: 60-80$, $K: 75-85$) yer alan kümelenme nohut (chickpea) gibi ürünlerin orta dereceli ve dengeli bir besin ihtiyacı olduğunu göstermektedir.
- Düşük ve Yoğun Kümelenme: Grafiğin sol alt kısmında ($P < 60$, $K < 50$) ise birçok ürünün (pirinç, mısır, pamuk vb.) verileri birbirine daha yakın değerlerde toplanmıştır. Bu bölgedeki ürünlerin birbirlerinden ayırt edilebilmesi için sıcaklık, nem ve yağış gibi diğer iklimsel özelliklerin model tarafından kullanılması kritik önem taşımaktadır.

Bu görselleştirme, fosfor ve potasyumun sadece birbiriyle ilişkili olmadığını, aynı zamanda ürün sınıflandırmasında en belirleyici özelliklerden (feature) biri olduğunu doğrulamaktadır.

2.4. EDA aşaması sonucunda şu çıkarımlar yapılmıştır:

- Veri setinde eksik değer olmadığı için doldurma yöntemlerine gerek duyulmamıştır.
- Hedef değişkenin tam dengeli olması, model başarısını ölçerken doğrudan doğruluk (accuracy) değerine güvenebileceğimizi kanıtlamıştır.
- Potasyum ve Fosfor arasındaki yüksek korelasyon, modelin bu iki özelliği birlikte değerlendirerek belirli meyve türlerini kolayca ayırt edebileceğini göstermektedir.

VERİ ÖNİŞLEME

3.1. Eksik Veri Stratejisi ve Gerekçesi

Yapılan analizler sonucunda veri setinde herhangi bir eksik değer saptanmadığı için (0 eksik veri) doldurma veya satır silme işlemi yapılmasına gerek duyulmamıştır.

3.2. Kategorik Değişken Kodlaması (Label Encoding)

Veri setindeki bağımsız değişkenlerin (N, P, K, sıcaklık vb.) tamamı sayısal verilerden oluşmaktadır. Ancak tahmin edilmesi beklenen hedef değişken (target variable) olan ürün isimleri (rice, maize, chickpea vb.) metin formatında, yani kategorik bir yapıdadır.

Matematiksel modellerin ve algoritmaların bu veriler üzerinde işlem yapabilmesi için metin tabanlı etiketlerin sayısal değerlere dönüştürülmesi gerekmektedir. Bu projede, her bir benzersiz ürün ismine 0 ile 21 arasında bir tam sayı atanmasını sağlayan Label Encoding yöntemi uygulanmıştır.

Bu dönüşüm sonucunda hedef değişken şu şekilde yapılandırılmıştır:

- Alfabetik sıraya göre ilk ürün olan apple 0, banana 1 değerini alırken, listenin sonundaki rice ve watermelon gibi ürünler ilgili tam sayı karşılıklarını (20 ve 21 gibi) almıştır.
- Toplamda 22 farklı sınıf olduğu için model, her bir örneği bu 22 sayısal değerden birine atayacak şekilde eğitilmiştir.

Bu işlem sayesinde hedef değişken, modelin kayıp fonksiyonlarını (loss functions) hesaplayabileceği ve sınıflandırma yapabileceği uygun bir sayısal formata getirilmiştir.

One-Hot her sınıfa ayrı bir sütun açtığı için kalabalık yaratır, Label Encoding ise her şeyi tek bir sütunda rakamla (0-21) çözer. Hedef değişken (tahmin edilecek şey) ürün ismi olduğu için Label Encoding her zaman daha profesyonel ve standart bir yaklaşımdır.

3.3. Veri Ölçeklendirme (StandardScaler)

Veri setindeki özelliklerin değer aralıkları birbirinden oldukça farklıdır; örneğin yıllık yağış miktarı 0 ile 300 mm arasında değişirken, pH değerleri 3 ile 9 gibi çok daha dar bir aralıkta seyretmektedir. Bu durum, Lojistik Regresyon ve SVM gibi katsayı veya mesafe tabanlı modellerin, sayısal olarak daha büyük değerlere sahip özelliklere (yağış miktarı gibi) hatalı bir şekilde daha fazla ağırlık vermesine neden olabilir.

Bu sorunu önlemek amacıyla, tüm özelliklerin ortalamasını 0 ve standart sapmasını 1 olacak şekilde dönüştüren StandardScaler yöntemi tercih edilmiştir. Bu sayede tüm özellikler aynı ölçeğe getirilerek model üzerindeki etkileri dengelenmiştir. Karar ağacı tabanlı modeller (Random Forest vb.) için ölçeklendirme zorunlu olmasa da, modeller arası tutarlı bir karşılaştırma yapabilmek ve Pipeline bütünlüğünü korumak adına bu işlem tüm süreçlere dahil edilmiştir.

Ayrıca, ölçeklendirme işlemi eğitim ve test setlerine ayrı ayrı uygulanacak şekilde tasarlanmıştır. Bu yaklaşım, test setindeki bilgilerin eğitim sürecine dahil olmasını engelleyerek Veri Sızıntısı (Data Leakage) hatasının önüne geçilmesini ve modelin gerçek dünya verilerindeki başarısının daha doğru ölçülmesini sağlamaktadır.

3.4. Veri Bölme (Train / Validation / Test Split)

Modelin eğitim sürecinde veriyi sadece eğitim ve test olarak ikiye bölmek, hiperparametre optimizasyonu sırasında test setine dolaylı yoldan sızıntı yapılmasına (overfitting to test set) neden olabilir. Bu riski yönetmek ve modelin gerçek performansını en objektif şekilde ölçmek adına veri seti üç aşamalı bir yapıya bölünmüştür:

Bölüm Oranları ve Strateji

Veri seti %60 Eğitim (Train), %20 Doğrulama (Validation) ve %20 Test seti olacak şekilde ayrılmıştır.

- Eğitim Seti (%60): Modellerin öğrenme sürecinde ağırlıklarını ve katsayılarını belirlemek için kullanılmıştır.
- Doğrulama Seti (%20): GridSearchCV ile yapılan hiperparametre optimizasyonu sırasında en iyi model ayarlarını seçmek ve eğitim sürecini izlemek için kullanılmıştır.
- Test Seti (%20): Modelin daha önce hiç görmediği veriler üzerindeki nihai başarısını ölçmek ve son raporlama için ayrılmıştır.

Tekrarlanabilirlik ve Rastgelelik

Veri bölme işlemi sırasında scikit-learn kütüphanesinin `train_test_split` fonksiyonu kullanılmıştır. Tüm deneysel süreçlerin ve sonuçların tekrarlanabilir olması adına `random_state` değeri 42 olarak sabitlenmiştir. Bu sayede, kod her çalıştırıldığında aynı veri örneklerinin aynı setlere düşmesi garanti altına alınmıştır.

Sınıf Dengesi Korunumu (Stratify)

Veri setindeki 22 farklı ürünün her birinden eşit sayıda örnek (100 adet) bulunduğu için, bölme işlemi sırasında her setin içinde bu ürünlerin oranının korunmasına dikkat edilmiştir. Böylece eğitim setinde olmayan bir ürünün test setinde karşımıza çıkması gibi hataların önüne geçilmiştir.

MODEL EĞİTİMİ VE HİPERPARAMETRE OPTİMİZASYONU

Lojistik Regresyon (Model 1)

Projenin ilk aşamasında, doğrusal bir sınıflandırıcı olan Lojistik Regresyon algoritması temel (baseline) model olarak seçilmiştir. Bu modelin seçilme nedeni, problemin karmaşıklığını ölçmek ve daha güçlü modeller için bir referans noktası oluşturmaktır.

1. Varsayılan (Baseline) Model Sonuçları

Model, kütüphane tarafından atanan varsayılan parametreler ve standart bir ölçeklendirme (StandardScaler) içeren bir Pipeline üzerinden eğitilmiştir.

- Kullanılan Varsayılan Parametreler: $C=1.0$, `solver='lbfgs'`, `max_iter=100`.
- Baseline Doğruluk Skoru (Validation): %97.27).

2. Hiperparametre Uzayı

Modelin performansını artırmak amacıyla belirlenen ve GridSearchCV yöntemiyle taranan parametre uzayı aşağıdaki tabloda sunulmuştur

Parametre	Açıklama	Denenecek Değerler
lr__C	Regülerizasyon gücü (Ters katsayı)	[0.1, 1, 10, 100]
lr__solver	Optimizasyon algoritması	['lbfgs', 'liblinear']
lr__max_iter	Maksimum iterasyon sayısı	[500, 1000]

- lr__C (Düzenleştirme): Modelin karmaşıklığını kontrol eder. Küçük değerler aşırı öğrenmeyi (overfitting) engellemek için kısıtlama getirirken, büyük değerler modelin verilere daha sıkı uyum sağlamasına izin verir.
- lr__solver (Çözücü): Hata payını minimize etmek için kullanılan matematiksel algoritmadır. 'lbfgs' çok sınıflı ve büyük verilerde performans sergilerken, 'liblinear' yüksek boyutlu verilerde kararlılık sağlar.
- lr__max_iter (İterasyon Sayısı): Algoritmanın en doğru katsayıları bulana kadar yapacağı maksimum deneme sayısıdır. 500 ve 1000 gibi yüksek değerler, modelin yarıda kesilmeden en iyi sonuca ulaşmasını (yakınsama) garantiler.

3. GridSearchCV Sonuçları ve Nihai Model

Sistemik arama süreci 5-katlı çapraz doğrulama (5-fold cross-validation) kullanılarak gerçekleştirilmiştir. Kod çıktıları neticesinde elde edilen kesin veriler şöyledir:

- En İyi Parametreler: {'lr__C': 100, 'lr__max_iter': 500, 'lr__solver': 'lbfgs'}
- En İyi Eğitim Skoru (CV): %97.95
- Nihai Model Doğrulama (Validation) Skoru: %97.73

Hiperparametre optimizasyonu sonucunda elde edilen %97.73'lük doğrulama skoru, modelin toprak ve iklim verilerini yüksek bir başarıyla sınıflandırdığını kanıtlamaktadır. En iyi sonuçları veren lr__C: 100 değeri, modelin eğitim verisine daha sıkı uyum sağlayarak karmaşık desenleri yakaladığını göstermektedir.

Random Forest (Model 2 - Ensemble Model)

Projenin ikinci ve daha güçlü modeli olarak, birden fazla karar ağacının birleşiminden oluşan bir topluluk (ensemble) öğrenme algoritması olan Random Forest seçilmiştir. Bu modelin temel seçilme nedeni, toprak ve iklim verileri arasındaki doğrusal olmayan karmaşık ilişkileri yüksek başarıyla yakalayabilmesidir.

1. Varsayılan (Baseline) Model Sonuçları Model, herhangi bir parametre müdahalesi yapılmadan varsayılan değerlerle bir Pipeline üzerinden eğitilmiştir.

- Kullanılan Varsayılan Parametreler: `n_estimators=100`, `max_depth=None`, `min_samples_split=2`.
- Baseline Doğruluk Skoru (Validation): %99.09.

2. Hiperparametre Uzayı Modelin daha kararlı sonuçlar vermesi ve aşırı öğrenmenin (overfitting) kontrol edilmesi amacıyla taranan parametreler aşağıdadır:

Parametre	Açıklama	Değerler
<code>rf_n_estimators</code>	Oluşturulacak ağaç sayısı	[50, 100, 200]
<code>rf_max_depth</code>	Ağaçların maksimum derinliği	[None, 10, 20]
<code>rf_min_samples_split</code>	Bir düğümü bölmek için gereken min. örnek	[2, 5]

- `rf_n_estimators`: Ormandaki ağaç sayısını belirler. Daha fazla ağaç genellikle daha kararlı sonuçlar ve daha iyi genelleme performansı sağlar.
- `rf_max_depth`: Her bir ağacın ne kadar derinleşebileceğini sınırlar. None (sınırsız) seçeneği, ağaçların tüm yapraklar saf hale gelene kadar büyümesine izin vererek karmaşıklığı artırır.
- `rf_min_samples_split`: Bir karar düğümünün bölünmesi için gereken minimum veri miktarını belirler. Bu değerin düşük tutulması (2), modelin verideki ince detayları öğrenmesine olanak tanır.

3. GridSearchCV Sonuçları ve Nihai Model Sistemik arama süreci 5-katlı çapraz doğrulama ile 18 farklı kombinasyon denenerek tamamlanmıştır. Görsellerdeki kod çıktılarına göre sonuçlar şöyledir:

- En İyi Parametreler: `{'rf_max_depth': None, 'rf_min_samples_split': 2, 'rf_n_estimators': 100}`
- Nihai Model Doğrulama (Validation) Skoru: %99.09

Random Forest modelinin hem baseline hem de tuned skorunun aynı çıkması (%99.09), varsayılan parametrelerin bu veri seti için zaten oldukça optimize olduğunu göstermektedir.

XGBoost (Extreme Gradient Boosting - Model 3)

Projenin üçüncü ve son modeli olarak, gradyan artırma (gradient boosting) temelli ve performans odaklı bir algoritma olan XGBoost seçilmiştir. Bu model, hem yüksek hızı hem de karmaşık veri

setlerinde aşırı öğrenmeyi engelleyen düzenleme (regularization) yetenekleri nedeniyle modern makine öğrenimi projelerinde standart kabul edilmektedir.

1. Varsayılan (Baseline) Model Sonuçları Model, varsayılan parametreler kullanılarak Pipeline üzerinden eğitilmiştir.

- Kullanılan Varsayılan Parametreler: `n_estimators=100`, `learning_rate=0.3`, `max_depth=6`.
- Baseline Doğruluk Skoru (Validation): %99.09.

2. Hiperparametre Uzayı XGBoost modelinin esnekliğini kontrol etmek ve en iyi öğrenme hızını bulmak için şu parametreler taranmıştır:

Parametre	Açıklama	Değerler
<code>xgb__n_estimators</code>	Oluşturulacak toplam ağaç sayısı	[50, 100, 200]
<code>xgb__learning_rate</code>	Her adımda hataların ne kadar düzeltileceği (Öğrenme hızı)	[0.01, 0.1, 0.2]
<code>xgb__max_depth</code>	Her bir ağacın maksimum derinliği	[3, 5, 7]

- `xgb__learning_rate`: Her yeni eklenen ağacın hatayı düzeltme hızını belirler. Düşük değerler (0.1), modelin daha yavaş ama daha sağlam öğrenmesini sağlar.
- `xgb__n_estimators`: Modelin kaç tane ardışık ağaç oluşturacağını belirler. Her ağaç bir önceki ağacın hatalarını düzeltmeye çalışır.
- `xgb__max_depth`: Ağaçların derinliğini sınırlayarak modelin çok karmaşık hale gelip veriyi ezberlemesini (overfitting) engeller.

3. GridSearchCV Sonuçları ve Nihai

Model Yapılan sistematik arama sonucunda, görseldeki kod çıktılarına dayanan sonuçlar şöyledir:

- En İyi Parametreler: {'xgb__learning_rate': 0.1, 'xgb__max_depth': 5, 'xgb__n_estimators': 100}
- En İyi Eğitim Skoru (CV): %99.47
- Nihai Model Doğrulama (Validation) Skoru: %99.09

Optimizasyon sonuçları incelendiğinde, öğrenme hızının (`learning_rate`) 0.1 olarak belirlenmesinin ve ağaç derinliğinin (`max_depth`) 5 seviyesinde tutulmasının modelin genelleme yeteneğini artırdığı görülmektedir. Eğitim skoru (%99.47) ile doğrulama skoru (%99.09) arasındaki farkın oldukça düşük olması, modelin aşırı öğrenme (overfitting) yapmadan yüksek başarıyla çalıştığını kanıtlamaktadır.


MODEL KARŞILAŞTIRMA VE DEĞERLENDİRME

Proje kapsamında eğitilen tüm modeller; Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall), F1-Skoru ve Eğitim Süresi kriterlerine göre karşılaştırılmıştır. Aşağıdaki tablo, modellerin test seti üzerindeki nihai performanslarını özetlemektedir:

	Model	Accuracy	Precision	Recall	F1	Eğitim Süresi
0	Logistic Regression (Baseline)	0.9705	0.9717	0.9705	0.9703	0.1349 sn
1	Random Forest (Default)	0.9977	0.9978	0.9977	0.9977	0.4911 sn
2	Random Forest (Tuned)	0.9977	0.9978	0.9977	0.9977	0.4931 sn
3	XGBoost (Default)	0.9886	0.9894	0.9886	0.9885	0.8540 sn
4	XGBoost (Tuned)	0.9841	0.9850	0.9841	0.9839	1.2220 sn

- En Başarılı Model: Yapılan karşılaştırmalar sonucunda hem varsayılan (default) hem de optimize edilmiş (tuned) haliyle Random Forest modeli %99.77 doğruluk oranı ile projenin en başarılı algoritması olmuştur.
- Hız ve Verimlilik: Lojistik Regresyon (Baseline) en hızlı çalışan model olmasına rağmen başarı oranı diğerlerinin gerisinde kalmıştır. Random Forest, hem çok yüksek doğruluk sunması hem de XGBoost'a göre daha kısa sürede eğitilmesi (yaklaşık 0.49 sn) nedeniyle en verimli model olarak öne çıkmaktadır.
- Optimizasyon Etkisi: Random Forest modelinde varsayılan parametrelerin zaten çok yüksek sonuç vermesi, veri setindeki sınıfların (ürünlerin) birbirinden çok net özelliklerle ayrıldığını göstermektedir. XGBoost modelinde ise hiperparametre optimizasyonu sonrası test skorunda çok küçük bir düşüş gözlemlenmiş; bu durum modelin eğitim verisine çok sıkı uyum sağlamasından (overfitting belirtisi) kaynaklanmış olabilir.


Hata Matrisi (Confusion Matrix) ve Yanlış Sınıflandırma Analizi



Modelin tahmin başarısını sınıf bazında incelemek amacıyla oluşturulan Hata Matrisi, sistemin ayırt edici gücünü net bir şekilde ortaya koymaktadır:

- **Diyagonal Başarı (Mavi Hat):** Matrisin sol üst köşesinden sağ alt köşesine uzanan koyu mavi kareler, modelin gerçek sınıfları doğru tahmin etme oranını temsil etmektedir. Örneğin "apple" ve "banana" gibi birçok sınıfta 20 test örneğinin tamamı (%100 başarı) hatasız tahmin edilmiştir.
- **Hata Dağılımı:** Diyagonal çizginin dışında kalan çok az sayıdaki veri noktası (örneğin Jute sınıfındaki 2 örneğin kahve/coffee ile karıştırılması), modelin nadir de olsa benzer çevresel ihtiyaçlara sahip ürünler arasında tereddüt yaşadığını göstermektedir.
- **N-P-K ve İklim Etkisi:** Toplam 440 test örneği içerisinde sadece 3-4 örneğin yanlış sınıflandırılmış olması, veri setindeki Azot (N), Fosfor (P), Potasyum (K) değerleri ile sıcaklık, nem ve yağış değişkenlerinin ürünleri birbirinden ayırmak için "yüksek ayırt edici" birer öznelik olduğunu kanıtlamaktadır.

Özellik Önemi (Feature Importance) Analizi




En yüksek performansı sergileyen Random Forest modelinin, tahmin yaparken hangi değişkenlere daha fazla ağırlık verdiğini anlamak amacıyla "Feature Importance" analizi gerçekleştirilmiştir.

Grafikteki verilere göre öne çıkan sonuçlar şöyledir:

- **En Belirleyici Faktörler:** Topraktaki Rainfall (Yağış Miktarı) ve Humidity (Nem), modelin ürün seçimi yaparken kullandığı en kritik iki değişkendir. Bu durum, bitkilerin su ihtiyacının tür ayırımında birincil öncelik olduğunu göstermektedir.
- **Besin Değerlerinin Etkisi:** Toprak besin elementleri arasında Potasyum (K) ve Azot (N), ürün tahmininde yüksek öneme sahipken; Fosfor (P) değerinin bu veri seti özelinde daha ikincil bir rol oynadığı gözlemlenmiştir.
- **İklim ve Toprak Dengesi:** Sıcaklık ve pH değerleri de karar verme sürecine katkı sağlamakla birlikte, yağış ve nem kadar keskin bir ayırım yaratmamaktadır.

ROC Eğrisi ve AUC (Alan Altındaki Bölge) Analizi



Sınıflandırma projelerinde modelin performansını ölçen en kritik metriklerden biri olan ROC (Receiver Operating Characteristic) eğrisi analizi, Random Forest modeli üzerinde gerçekleştirilmiştir. Elde edilen sonuçlar modelin ayırt edici gücünü şu şekilde özetlemektedir:

- **AUC Skoru (1.00):** Analiz sonucunda modelin AUC (Area Under Curve) değeri 1.00 olarak hesaplanmıştır. Bu değer, modelin sınıfları (ürün türlerini) birbirinden ayırma konusunda %100 başarı sağladığını ve mükemmel bir sınıflandırıcı olduğunu göstermektedir.
- **Eğri Analizi:** Grafikte turuncu çizgi ile temsil edilen model performansı, sol üst köşeye dik bir açıyla birleşmektedir. Bu durum, modelin "Yanlış Pozitif Oranı" (False Positive Rate) 0 iken "Doğru Pozitif Oranı"nı (True Positive Rate) 1'e ulaştırdığını, yani yanlış alarm vermeden tüm doğru sınıfları yakaladığını kanıtlamaktadır.
- **Şans Eseri Tahmin Hattı:** Grafikteki kesikli mavi çizgi, rastgele yapılan bir tahmini temsil etmektedir. Modelimizin bu hattın çok üzerinde ve sol üst köşeye yapışık olması, toprak ve

iklim verilerinin rastlantıdan uzak, bilimsel olarak güçlü bir tahmin altyapısı sunduğunu ispatlamaktadır.

ROC eğrisinin sunduğu bu kusursuz profil, akıllı tarım sisteminin farklı ürün gruplarını (örneğin neme duyarlı ürünler ile kuraklığa dayanıklı ürünler) hiçbir karışıklığa yer vermeden başarıyla ayırt edebildiğini doğrulamaktadır.

SONUÇ

1. En iyi performansı hangi model gösterdi ve neden? Yapılan testler sonucunda Random Forest algoritması en yüksek başarıyı sergilemiştir. Bunun temel nedeni, tarım verilerinin (N, P, K, yağış vb.) doğrusal olmayan karmaşık eşik değerlerine sahip olmasıdır. Ağaç tabanlı modeller, veriyi dallara ayırarak bu hassas aralıkları Lojistik Regresyon gibi doğrusal modellerden çok daha başarılı bir şekilde yakalayabilmektedir.

2. Hiperparametre optimizasyonu ne kadar fark yarattı? Varsayılan parametrelerle alınan sonuçlar zaten yüksek olsa da, GridSearchCV optimizasyonu sayesinde modellerin ezberleme (overfitting) yapmadığı doğrulanmıştır. Özellikle Random Forest modelinde derinlik ve ağaç sayısı optimizasyonu, modelin %99.77 gibi kusursuz bir hassasiyete ulaşmasını sağlamıştır.

Modellerin Güçlü ve Zayıf Yönleri

- Lojistik Regresyon:
 - Güçlü: Eğitim hızı çok yüksektir ve katsayılar üzerinden yorumlanması kolaydır.
 - Zayıf: Verideki dairesel ve karmaşık ilişkileri anlamakta zorlandığı için başarısı diğerlerine göre bir miktar düşüktür.
- Random Forest:
 - Güçlü: Eksik verilere karşı dayanıklıdır ve en yüksek kararlılığı sunar. Önemli özellikleri (Yağış, Nem) çok iyi belirler.
 - Zayıf: Ağaç sayısı çok arttığında bellek kullanımı ve işlem yükü artabilir.
- XGBoost:
 - Güçlü: Hız ve performans dengesi mükemmeldir. Büyük veri setlerinde Random Forest'tan daha hızlı sonuç verir.
 - Zayıf: Parametre ayarlarına karşı çok hassastır; yanlış yapılandırıldığında hataya meyillidir.

Gelecek Çalışma Önerileri

Mevcut sistemin başarısını gerçek hayatta daha ileriye taşımak için şu adımlar atılabilir:

- **Veri Çeşitliliği:** Modele rakım (irtifa) ve rüzgar hızı gibi ek ekolojik veriler eklenerek tahmin gücü artırılabilir.
- **Zaman Serisi Analizi:** Geçmişe dönük 10 yıllık iklim trendleri kullanılarak gelecek yıllar için ürün rotasyonu planlaması yapılabilir.
- **Mobil Entegrasyon:** Geliştirilen model bir API haline getirilerek, çiftçilerin tarladan anlık veri girişi yapıp tavsiye alabileceği bir mobil uygulamaya dönüştürülebilir.